

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이론 데이터에 대한 분석 수행

시계열 데이터 분석 (정석)

ACF plot과 PACF plot을 통해 모수를 추정하여 차분을 수행하여 분석하는 방법

#01. 작업준비

패키지 참조

pmdarima 패키지의 설치가 필요하다.

```
from pandas import read_excel
from matplotlib import pyplot as plt
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.tsa.stattools import adfuller
from pmdarima.arima import auto_arima
import seaborn as sb
import sys
```

데이터 가져오기

```
df = read_excel("https://data.hossam.kr/E06/air_passengers.xlsx")
df
```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이론 데이터에 대한 분석 수행

	Month	Passengers
0	1949-01-01	112
1	1949-02-01	118
2	1949-03-01	132
3	1949-04-01	129
4	1949-05-01	121
...
139	1960-08-01	606
140	1960-09-01	508
141	1960-10-01	461
142	1960-11-01	390
143	1960-12-01	432

144 rows × 2 columns

#02. 데이터의 정상성 확인

그래프 초기화

```
plt.rcParams["font.family"] = 'AppleGothic' if sys.platform == 'darwin'
plt.rcParams["font.size"] = 12
```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA


원본 데이터에 대한 분석 수행

```
plt.rcParams["figure.figsize"] = (15, 5)
plt.rcParams["axes.unicode_minus"] = False
```

데이터 시각화

데이터의 패턴은 보이지만 비정상성임을 알 수 있다.

```
plt.figure()
sb.lineplot(data=df, y='Passengers', x='Month')
plt.grid()
plt.show()
plt.close()
```



원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이론 데이터에 대한 분석 수행

가설	내용
귀무가설	데이터가 정상성과 다르다 (=비정상성임을 의미)
대립가설	데이터가 정상성이다.

```

ar = adfuller(df['Passengers'])

print('ADF Statistic: %f' % ar[0])
print('p-value: %f' % ar[1])
print('num of lags: %f' % ar[2])
print('num of observations: %f' % ar[3])
print('Critical Values:')
for key, value in ar[4].items():
    print('\t%s: %.3f' % (key, value))

print('데이터 정상성 여부: ', '정상' if ar[1] < 0.05 else '비정상')

```

```

ADF Statistic: 0.815369
p-value: 0.991880
num of lags: 13.000000
num of observations: 130.000000
Critical Values:
    1%: -3.482
    5%: -2.884
   10%: -2.579
데이터 정상성 여부: 비정상

```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이브 데이터에 대한 분석 수행

#03. ACF, PACF 검정

정상 시계열 데이터의 경우, ACF는 상대적으로 빠르게 0(상관관계 0)에 접근한다.

비정상 시계열 데이터의 경우, ACF는 천천히 감소하며 종종 큰 양의 값을 갖는다.

차분이 필요 없다고 판정되었으므로 원본 데이터로 진행한다.

구분	$AR(p)$ 모델 적합	$MA(q)$ 모델 적합
ACF plot	천천히 감소	첫 값으로부터 q 개 뒤에 끊긴다.
PACF plot	첫 값으로부터 p 개 뒤에 끊긴다.	천천히 감소

ACF Plot

```
plot_acf(df['Passengers'])
plt.show()
plt.close()
```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행


학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이론 데이터에 대한 분석 수행



PACF Plot

```
plot_pacf(df['Passengers'])
plt.show()
plt.close()
```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행


학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이론 데이터에 대한 분석 수행



결과 판정

구분	ACF plot	PACF plot
감소	상대적으로 완만	상대적으로 급격
파란박스 진입 지점	$p = 1$	$q = 1$

이 결과를 고려하여 완만함을 보이는 ACF 플롯을 채택

 $AR(1)$ 모델로 결정

p-value가 0.05보다 작으므로 귀무가설을 기각하도 대립가설 채택. 즉 예제 데이터는 정상성 데이터

만약 귀무가설이 채택되어 정상성이 아니라고 판단될 경우 차분을 1회 수행하고 다시 ADF 검정을 수행

대립가설이 채택될 때 까지 이 과정을 반복함

반복횟수가 d 값이 됨

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이전 데이터에 대한 분석 수행

이 예제에서는 1번의 차분은 수행해야 한다고 가정함

#03. ARIMA 분석 수행

```
model = ARIMA(df['Passengers'], order=(1,1,0))
fit = model.fit()
print(fit.summary())
```

SARIMAX Results

Dep. Variable:	Passengers	No. Observations:	-6
Model:	ARIMA(1, 1, 0)	Log Likelihood	14
Date:	Thu, 03 Aug 2023	AIC	14
Time:	14:04:34	BIC	14
Sample:	0	HQIC	14
	- 144		
Covariance Type:	opg		

	coef	std err	z	P> z	[0.025	12
ar.L1	0.3066	0.080	3.849	0.000	0.150	
sigma2	1029.2429	103.738	9.922	0.000	825.920	

Ljung-Box (L1) (Q):	0.66	Jarque-Bera (JB):
Prob(Q):	0.42	Prob(JB):
Heteroskedasticity (H):	8.35	Skew:
Prob(H) (two-sided):	0.00	Kurtosis:

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이전 데이터에 대한 분석 수행

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (c

학습 결과에 대한 예측값 생성

```
start_index = 0
end_index = len(df['Passengers'])
pd = fit.predict(start=start_index, end=end_index)
pd
```

```
0      0.000000
1    112.038959
2    119.839303
3    136.291707
4    128.080349
...
140   601.095192
141   477.958052
142   446.592127
143   368.234915
144   444.875121
Name: predicted_mean, Length: 145, dtype: float64
```

이후 10 단계의 예측값 생성

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이론 데이터에 대한 분석 수행

```
fc = fit.forecast(10)
fc
```

```
144    444.875121
145    448.821995
146    450.031912
147    450.402812
148    450.516512
149    450.551367
150    450.562051
151    450.565327
152    450.566331
153    450.566639
Name: predicted_mean, dtype: float64
```

관측치와 예측치의 비교 결과 시각화

```
x = list(range(0, len(df), 20))
x
```

```
[0, 20, 40, 60, 80, 100, 120, 140]
```

```
xlabels = []

for i in x:
```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이전 데이터에 대한 분석 수행

```
xlabels.append(df.loc[i, 'Month'].strftime('%Y-%m-%d'))
```

xlabels

```
[ '1949-01-01',
  '1950-09-01',
  '1952-05-01',
  '1954-01-01',
  '1955-09-01',
  '1957-05-01',
  '1959-01-01',
  '1960-09-01']
```

```
plt.figure()
sb.lineplot(x=df.index, y=df['Passengers']) # 원본
sb.lineplot(x=pd.index, y=pd)               # 원본을 토대로 학습하여 예측한 값
sb.lineplot(x=fc.index, y=fc)               # 이후 10단계를 예측한 값

plt.xticks(x, xlabels, rotation=0)

plt.grid()
plt.show()
plt.close()
```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행


학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

원본 데이터에 대한 분석 수행



#05. Auto ARIMA

최적의 ARIMA 모델을 자동으로 찾아서 검색을 수행해 주는 기능

원본 데이터에 대한 분석 수행

예제 데이터에서는 파라미터를 변경하여 수행한 결과와 기본값만으로 수행한 결과가 동일하였다.

```

model = auto_arima(x=df['Passengers'],
                    y=df['Month'],
                    d=1,
                    start_p=1,
                    max_p=3,
                    start_q=1,
                    max_q=3,
                    seasonal=True,
                    trace=True,
                    error_action='ignore',
                    # 차분 횟수 (default=1)
                    # default=2
                    # default=5
                    # default=2
                    # default=5
                    # 계절성을 고려 여부 (default=
                    # 자동으로 ARIMA 모델을 찾는 과
                    # 에러가 발생하면 무시

```

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이본 데이터에 대한 분석 수행

suppress_warnings=True # 경고를 무시

)

Performing stepwise search to minimize aic

ARIMA(1,1,1)(0,0,0)[0] intercept : AIC=inf, Time=0.10 sec

ARIMA(0,1,0)(0,0,0)[0] intercept : AIC=9529.255, Time=0.01 sec

ARIMA(1,1,0)(0,0,0)[0] intercept : AIC=76478.633, Time=0.05 sec

ARIMA(0,1,1)(0,0,0)[0] intercept : AIC=9534.927, Time=0.12 sec

ARIMA(0,1,0)(0,0,0)[0] : AIC=10562.511, Time=0.01 sec

Best model: ARIMA(0,1,0)(0,0,0)[0] intercept

Total fit time: 0.298 seconds

분석 결과 확인

print(model.summary())

SARIMAX Results

Dep. Variable:	y	No. Observations:	
Model:	SARIMAX(0, 1, 0)	Log Likelihood	-47
Date:	Thu, 03 Aug 2023	AIC	95
Time:	14:04:35	BIC	95
Sample:	0	HQIC	95
	- 144		
Covariance Type:	opg		

시계열 데이터 분석 (정석)

#01. 작업준비

패키지 참조

데이터 가져오기

#02. 데이터의 정상성 확인

그래프 초기화

데이터 시각화

원본 데이터에 대한 ADF 테스트

ADF 테스트의 가설

#03. ACF, PACF 검정

ACF Plot

PACF Plot

결과 판정

#03. ARIMA 분석 수행

학습 결과에 대한 예측값 생성

이후 10 단계의 예측값 생성

관측치와 예측치의 비교 결과 시각화

#05. Auto ARIMA

이전 데이터에 대한 분석 수행

	coef	std err	z	P> z	[0.025	
intercept	2.629e+15	5.89e+12	446.227	0.000	2.62e+15	2.
sigma2	4.965e+27	0.069	7.23e+28	0.000	4.97e+27	4.
Ljung-Box (L1) (Q):						
			33.61	Jarque-Bera (JB):		
Prob(Q):			0.00	Prob(JB):		
Heteroskedasticity (H):			1.00	Skew:		
Prob(H) (two-sided):			1.00	Kurtosis:		

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (c

[2] Covariance matrix is singular or near-singular, with condition numbe

분석 결과에 대한 학습 및 예측값 얻기